Laboratorio 6 Parte 1

En este laboratorio, estaremos repasando los conceptos de Generative Adversarial Networks En la segunda parte nos acercaremos a esta arquitectura a través de buscar generar numeros que parecieran ser generados a mano. Esta vez ya no usaremos versiones deprecadas de la librería de PyTorch, por ende, creen un nuevo virtual env con las librerías más recientes que puedan por favor.

Al igual que en laboratorios anteriores, para este laboratorio estaremos usando una herramienta para Jupyter Notebooks que facilitará la calificación, no solo asegurándo que ustedes tengan una nota pronto sino también mostrandoles su nota final al terminar el laboratorio.

De nuevo me discupo si algo no sale bien, seguiremos mejorando conforme vayamos iterando. Siempre pido su comprensión y colaboración si algo no funciona como debería.

Al igual que en el laboratorio pasado, estaremos usando la librería de Dr John Williamson et al de la University of Glasgow, además de ciertas piezas de código de Dr Bjorn Jensen de su curso de Introduction to Data Science and System de la University of Glasgow para la visualización de sus calificaciones.

NOTA: Ahora tambien hay una tercera dependecia que se necesita instalar. Ver la celda de abajo por favor

```
# Una vez instalada la librería por favor, recuerden volverla a comentar.
# !pip install -U --force-reinstall --no-cache https://github.com/johnhw/jhwutils/zipball/master
# !pip install scikit-image
# !pip install -U --force-reinstall --no-cache https://github.com/AlbertS789/lautils/zipball/mast
```

```
import numpy as np
import copy
import matplotlib.pyplot as plt
import scipy
from PIL import Image
import os
from collections import defaultdict

#from IPython import display
#from base64 import b64decode


# Other imports
from unittest.mock import patch
from uuid import getnode as get_mac

from jhwutils.checkarr import array_hash, check_hash, check_scalar, check_string, array_hash, _ch
import jhwutils.image_audio as ia
import jhwutils.tick as tick
from lautils.gradeutils import new_representation, hex_to_float, compare_numbers, compare_lists_b

###
```

```
tick.reset_marks()

%matplotlib inline
```

```
# Celda escondida para utlidades necesarias, por favor NO edite esta celda
```

Información del estudiante en dos variables

- carne_1 : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- firma_mecanografiada_1: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaracion que este trabajo es propio (es decir, no hay plagio)
- carne_2 : un string con su carne (e.g. "12281"), debe ser de al menos 5 caracteres.
- firma_mecanografiada_2: un string con su nombre (e.g. "Albero Suriano") que se usará para la declaracion que este trabajo es propio (es decir, no hay plagio)

```
# carne_1 =
# firma_mecanografiada_1 =
# carne_2 =
# firma_mecanografiada_2 =
# YOUR CODE HERE
carne_1 = "161250"
firma_mecanografiada_1 = "Manuel Archila"
carne_2 = "161250"
firma_mecanografiada_2 = "Manuel Archila"
```

```
# Deberia poder ver dos checkmarks verdes [0 marks], que indican que su información básica está O

with tick.marks(0):
    assert(len(carne_1)>=5 and len(carne_2)>=5)

with tick.marks(0):
    assert(len(firma_mecanografiada_1)>0 and len(firma_mecanografiada_2)>0)
```

✓ [0 marks]

✓ [0 marks]

Introducción

Créditos: Esta parte de este laboratorio está tomado y basado en uno de los blogs de Renato Candido, así como las imagenes presentadas en este laboratorio a menos que se indique lo contrario.

Las redes generativas adversarias también pueden generar muestras de alta dimensionalidad, como imágenes. En este ejemplo, se va a utilizar una GAN para generar imágenes de dígitos escritos a mano. Para ello, se entrenarán los modelos utilizando el conjunto de datos MNIST de dígitos escritos a mano, que está incluido en el paquete torchvision.

Dado que este ejemplo utiliza imágenes en el conjunto de datos de entrenamiento, los modelos necesitan ser más complejos, con un mayor número de parámetros. Esto hace que el proceso de entrenamiento sea más lento, llevando alrededor de dos minutos por época (aproximadamente) al ejecutarse en la CPU. Se necesitarán alrededor de cincuenta épocas para obtener un resultado relevante, por lo que el tiempo total de entrenamiento al usar una CPU es de alrededor de cien minutos.

Para reducir el tiempo de entrenamiento, se puede utilizar una GPU si está disponible. Sin embargo, será necesario mover manualmente tensores y modelos a la GPU para usarlos en el proceso de entrenamiento.

Se puede asegurar que el código se ejecutará en cualquier configuración creando un objeto de dispositivo que apunte a la CPU o, si está disponible, a la GPU. Más adelante, se utilizará este dispositivo para definir dónde deben crearse los tensores y los modelos, utilizando la GPU si está disponible.

```
import torch
from torch import nn

import math
import matplotlib.pyplot as plt
import torchvision
import torchvision.transforms as transforms

import random
import numpy as np
```

```
seed_ = 111

def seed_all(seed_):
    random.seed(seed_)
    np.random.seed(seed_)
    torch.manual_seed(seed_)
    torch.cuda.manual_seed(seed_)
    torch.backends.cudnn.deterministic = True

seed_all(seed_)
```

```
device = ""
if torch.cuda.is_available():
```

```
    device = torch.device("cuda")
else:
    device = torch.device("cpu")
print(device)
```

```
cuda
```

Preparando la Data

El conjunto de datos MNIST consta de imágenes en escala de grises de 28 × 28 píxeles de dígitos escritos a mano del 0 al 9. Para usarlos con PyTorch, será necesario realizar algunas conversiones. Para ello, se define transform, una función que se utilizará al cargar los datos:

La función tiene dos partes:

- transforms.ToTensor() convierte los datos en un tensor de PyTorch.
- transforms.Normalize() convierte el rango de los coeficientes del tensor.

Los coeficientes originales proporcionados por transforms.ToTensor() varían de 0 a 1, y dado que los fondos de las imágenes son negros, la mayoría de los coeficientes son iguales a 0 cuando se representan utilizando este rango.

transforms.Normalize() cambia el rango de los coeficientes a -1 a 1 restando 0.5 de los coeficientes originales y dividiendo el resultado por 0.5. Con esta transformación, el número de elementos iguales a 0 en las muestras de entrada se reduce drásticamente, lo que ayuda en el entrenamiento de los modelos.

Los argumentos de transforms.Normalize() son dos tuplas, $(M_1, \ldots, M_n)$ y $(S_1, \ldots, S_n)$, donde n representa el número de canales de las imágenes. Las imágenes en escala de grises como las del conjunto de datos MNIST tienen solo un canal, por lo que las tuplas tienen solo un valor. Luego, para cada canal i de la imagen, transforms.Normalize() resta M_i de los coeficientes y divide el resultado por S_i.

Luego se pueden cargar los datos de entrenamiento utilizando torchvision.datasets.MNIST y realizar las conversiones utilizando transform

El argumento download=True garantiza que la primera vez que se ejecute el código, el conjunto de datos MNIST se descargará y almacenará en el directorio actual, como se indica en el argumento root.

Después que se ha creado train_set, se puede crear el cargador de datos como se hizo antes en la parte 1.

Cabe decir que se puede utilizar Matplotlib para trazar algunas muestras de los datos de entrenamiento. Para mejorar la visualización, se puede usar cmap=gray_r para invertir el mapa de colores y representar los dígitos en negro sobre un fondo blanco:

Como se puede ver más adelante, hay dígitos con diferentes estilos de escritura. A medida que la GAN aprende la distribución de los datos, también generará dígitos con diferentes estilos de escritura.

```
transform = transforms.Compose(
    [transforms.ToTensor(), transforms.Normalize((0.5,), (0.5,))]
```

```
)
```

```
train_set = torchvision.datasets.MNIST(
    root=".", train=True, download=True, transform=transform
)
```

```
batch_size = 32
train_loader = torch.utils.data.DataLoader(
    train_set, batch_size=batch_size, shuffle=True
)
```

```
real_samples, mnist_labels = next(iter(train_loader))
for i in range(16):
    ax = plt.subplot(4, 4, i + 1)
    plt.imshow(real_samples[i].reshape(28, 28), cmap="gray_r")
    plt.xticks([])
    plt.yticks([])
```

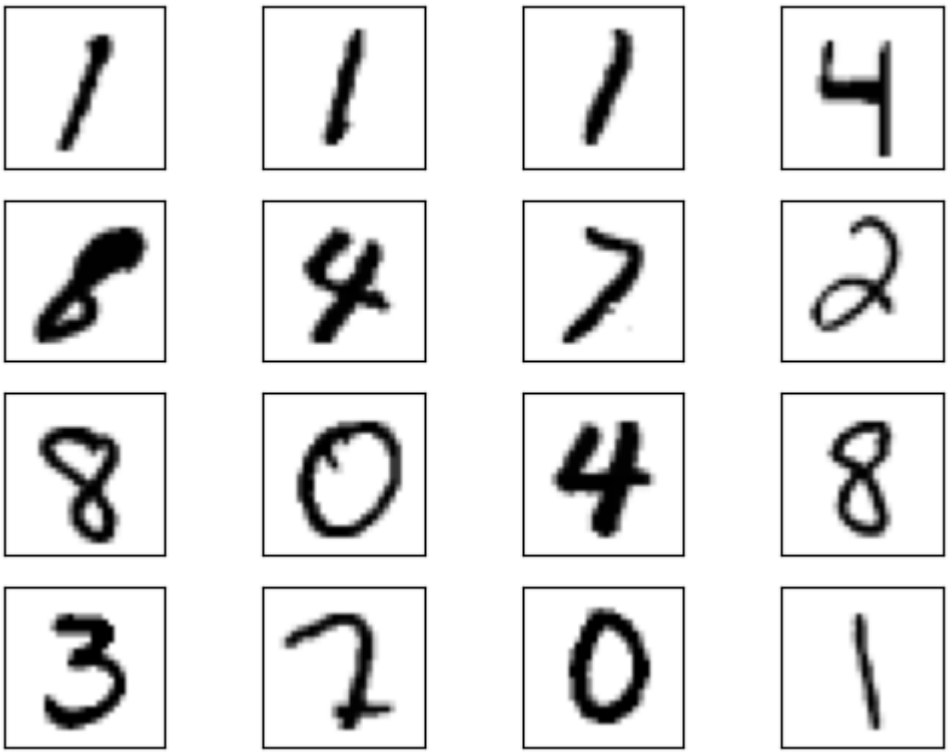

Implementando el Discriminador y el Generador

En este caso, el discriminador es una red neuronal MLP (multi-layer perceptron) que recibe una imagen de 28 × 28 píxeles y proporciona la probabilidad de que la imagen pertenezca a los datos reales de entrenamiento.

Para introducir los coeficientes de la imagen en la red neuronal MLP, se vectorizan para que la red neuronal reciba vectores con 784 coeficientes.

La vectorización ocurre cuando se ejecuta .forward(), ya que la llamada a x.view() convierte la forma del tensor de entrada. En este caso, la forma original de la entrada "x" es 32 × 1 × 28 × 28, donde 32 es el tamaño del batch que se ha configurado. Después de la conversión, la forma de "x" se convierte en 32 × 784, con cada línea representando los coeficientes de una imagen del conjunto de entrenamiento.

Para ejecutar el modelo de discriminador usando la GPU, hay que instanciarlo y enviarlo a la GPU con .to(). Para usar una GPU cuando haya una disponible, se puede enviar el modelo al objeto de dispositivo creado anteriormente.

Dado que el generador va a generar datos más complejos, es necesario aumentar las dimensiones de la entrada desde el espacio latente. En este caso, el generador va a recibir una entrada de 100 dimensiones y proporcionará una salida con 784 coeficientes, que se organizarán en un tensor de 28 × 28 que representa una imagen.

Luego, se utiliza la función tangente hiperbólica Tanh() como activación de la capa de salida, ya que los coeficientes de salida deben estar en el intervalo de -1 a 1 (por la normalización que se hizo anteriormente). Después, se instancia el generador y se envía a device para usar la GPU si está disponible.

```
class Discriminator(nn.Module):
    def __init__(self):
        super().__init__()
        self.model = nn.Sequential(
            # Aprox 11 lineas
            # lineal de la entrada dicha y salida 1024
            # ReLU
            # Dropout de 30%
            # Lineal de la entrada correspondiente y salida 512
            # ReLU
            # Dropout de 30%
            # Lienal de la entrada correspondiente y salida 256
            # ReLU
            # Dropout de 30%
            # Lineal de la entrada correspondiente y salida 1
            # Sigmoide
            # YOUR CODE HERE
            nn.Linear(784, 1024),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(1024, 512),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(512, 256),
            nn.ReLU(),
            nn.Dropout(0.3),
            nn.Linear(256, 1),
            nn.Sigmoid()
        )

    def forward(self, x):
```

```
        x = x.view(x.size(0), 784)
        output = self.model(x)
        return output
```

```
class Generator(nn.Module):
    def __init__(self):
        super().__init__()
        self.model = nn.Sequential(
            # Aprox 8 lienas para
            # Lineal input = 100, output = 256
            # ReLU
            # Lineal output = 512
            # ReLU
            # Lineal output = 1024
            # ReLU
            # Lineal output = 784
            # Tanh
            # YOUR CODE HERE
            nn.Linear(100, 256),
            nn.ReLU(),
            nn.Linear(256, 512),
            nn.ReLU(),
            nn.Linear(512, 1024),
            nn.ReLU(),
            nn.Linear(1024, 784),
            nn.Tanh()
        )

    def forward(self, x):
        output = self.model(x)
        output = output.view(x.size(0), 1, 28, 28)
        return output
```

Entrenando los Modelos

Para entrenar los modelos, es necesario definir los parámetros de entrenamiento y los optimizadores como se hizo en la parte anterior.

Para obtener un mejor resultado, se disminuye la tasa de aprendizaje de la primera parte. También se establece el número de épocas en 10 para reducir el tiempo de entrenamiento.

El ciclo de entrenamiento es muy similar al que se usó en la parte previa. Note como se envían los datos de entrenamiento a device para usar la GPU si está disponible

Algunos de los tensores no necesitan ser enviados explícitamente a la GPU con device. Este es el caso de generated_samples, que ya se envió a una GPU disponible, ya que latent_space_samples y generator se enviaron a la GPU previamente.

Dado que esta parte presenta modelos más complejos, el entrenamiento puede llevar un poco más de tiempo. Después de que termine, se pueden verificar los resultados generando algunas muestras de dígitos escritos a mano.

```
list_images = []

# Aprox 1 linea para que decidan donde guardar un set de imagen que vamos a generar de las grafic
# path_imgs =
# YOUR CODE HERE
path_imgs = "./imgs/"

#seed_all(seed_)

discriminator = Discriminator().to(device=device)
generator = Generator().to(device=device)

lr = 0.0001
num_epochs = 50
loss_function = nn.BCELoss()

optimizer_discriminator = torch.optim.Adam(discriminator.parameters(), lr=lr)
optimizer_generator = torch.optim.Adam(generator.parameters(), lr=lr)

for epoch in range(num_epochs):
    for n, (real_samples, mnist_labels) in enumerate(train_loader):
        # Data for training the discriminator
        real_samples = real_samples.to(device=device)
        real_samples_labels = torch.ones((batch_size, 1)).to(
            device=device
        )
        latent_space_samples = torch.randn((batch_size, 100)).to(
            device=device
        )
        generated_samples = generator(latent_space_samples)
        generated_samples_labels = torch.zeros((batch_size, 1)).to(
            device=device
        )
        all_samples = torch.cat((real_samples, generated_samples))
        all_samples_labels = torch.cat(
            (real_samples_labels, generated_samples_labels)
        )

        # Training the discriminator
        # Aprox 2 lineas para
        # setear el discriminador en zero_grad
        # output_discriminator =
        # YOUR CODE HERE
        discriminator.zero_grad()
        output_discriminator = discriminator(all_samples)
        loss_discriminator = loss_function(
```

```
        output_discriminator, all_samples_labels
    )
    # Aprox dos lineas para
    # llamar al paso backward sobre el loss_discriminator
    # llamar al optimizador sobre optimizer_discriminator
    # YOUR CODE HERE
    loss_discriminator.backward()
    optimizer_discriminator.step()

    # Data for training the generator
    latent_space_samples = torch.randn((batch_size, 100)).to(
        device=device
    )

    # Training the generator
    # Training the generator
    # Aprox 2 lineas para
    # setear el generador en zero_grad
    # output_discriminator =
    # YOUR CODE HERE
    generator.zero_grad()
    generated_samples = generator(latent_space_samples)
    output_discriminator = discriminator(generated_samples)
    output_discriminator_generated = discriminator(generated_samples)
    loss_generator = loss_function(
        output_discriminator_generated, real_samples_labels
    )

    # Aprox dos lineas para
    # llamar al paso backward sobre el loss_generator
    # llamar al optimizador sobre optimizer_generator
    # YOUR CODE HERE
    loss_generator.backward()
    optimizer_generator.step()

    # Guardamos las imagenes
    if epoch % 2 == 0 and n ==  batch_size - 1:
        generated_samples_detached = generated_samples.cpu().detach()
        for i in range(16):
            ax = plt.subplot(4, 4, i + 1)
            plt.imshow(generated_samples_detached[i].reshape(28, 28), cmap="gray_r")
            plt.xticks([])
            plt.yticks([])
            plt.title("Epoch "+str(epoch))
        name = path_imgs + "epoch_mnist"+str(epoch)+".jpg"
        plt.savefig(name, format="jpg")
        plt.close()
        list_images.append(name)

    # Show loss
```

```
        if n == batch_size - 1:
            print(f"Epoch: {epoch} Loss D.: {loss_discriminator}")
            print(f"Epoch: {epoch} Loss G.: {loss_generator}")
```

```
Epoch: 0 Loss D.: 0.5743626356124878
Epoch: 0 Loss G.: 0.4902080297470093
Epoch: 1 Loss D.: 0.03523636236786842
Epoch: 1 Loss G.: 4.416775703430176
Epoch: 2 Loss D.: 0.016907162964344025
Epoch: 2 Loss G.: 6.837886810302734
Epoch: 3 Loss D.: 0.012043973430991173
Epoch: 3 Loss G.: 6.21694803237915
Epoch: 4 Loss D.: 0.002179408213123679
Epoch: 4 Loss G.: 16.950241088867188
Epoch: 5 Loss D.: 0.09833214432001114
Epoch: 5 Loss G.: 5.363836765289307
Epoch: 6 Loss D.: 0.09949497878551483
Epoch: 6 Loss G.: 3.5778539180755615
Epoch: 7 Loss D.: 0.2144111692905426
Epoch: 7 Loss G.: 3.159391164779663
Epoch: 8 Loss D.: 0.24638915061950684
Epoch: 8 Loss G.: 1.9579854011535645
Epoch: 9 Loss D.: 0.25772058963775635
Epoch: 9 Loss G.: 2.03421688079834
Epoch: 10 Loss D.: 0.3207160234451294
Epoch: 10 Loss G.: 1.8347723484039307
Epoch: 11 Loss D.: 0.38585495948791504
Epoch: 11 Loss G.: 1.763363242149353
Epoch: 12 Loss D.: 0.4320119023323059
Epoch: 12 Loss G.: 1.5049651861190796
Epoch: 13 Loss D.: 0.5020086765289307
Epoch: 13 Loss G.: 1.3962130546569824
Epoch: 14 Loss D.: 0.4555712342262268
Epoch: 14 Loss G.: 1.1778101921081543
Epoch: 15 Loss D.: 0.44382157921791077
Epoch: 15 Loss G.: 1.1659209728240967
Epoch: 16 Loss D.: 0.4121793508529663
Epoch: 16 Loss G.: 1.33780837059021
Epoch: 17 Loss D.: 0.5476633310317993
Epoch: 17 Loss G.: 1.3547735214233398
Epoch: 18 Loss D.: 0.5385918617248535
Epoch: 18 Loss G.: 1.201533317565918
Epoch: 19 Loss D.: 0.6003187894821167
Epoch: 19 Loss G.: 1.3531044721603394
Epoch: 20 Loss D.: 0.5237895250320435
Epoch: 20 Loss G.: 0.9551297426223755
Epoch: 21 Loss D.: 0.5620752573013306
Epoch: 21 Loss G.: 1.2373816967010498
Epoch: 22 Loss D.: 0.4751594662666321
```

```
Epoch: 22 Loss G.: 1.0412487983703613
Epoch: 23 Loss D.: 0.49677038192749023
Epoch: 23 Loss G.: 1.0747551918029785
Epoch: 24 Loss D.: 0.5271953344345093
Epoch: 24 Loss G.: 1.0180602073669434
Epoch: 25 Loss D.: 0.6094131469726562
Epoch: 25 Loss G.: 1.0606403350830078
Epoch: 26 Loss D.: 0.6546658277511597
Epoch: 26 Loss G.: 1.187190055847168
Epoch: 27 Loss D.: 0.5759857296943665
Epoch: 27 Loss G.: 1.1213631629943848
Epoch: 28 Loss D.: 0.6083797812461853
Epoch: 28 Loss G.: 1.0745775699615479
Epoch: 29 Loss D.: 0.5490309000015259
Epoch: 29 Loss G.: 1.0489140748977661
Epoch: 30 Loss D.: 0.6319197416305542
Epoch: 30 Loss G.: 0.9944350719451904
Epoch: 31 Loss D.: 0.6160147786140442
Epoch: 31 Loss G.: 0.9819328188896179
Epoch: 32 Loss D.: 0.5661335587501526
Epoch: 32 Loss G.: 1.0311241149902344
Epoch: 33 Loss D.: 0.5815655589103699
Epoch: 33 Loss G.: 1.0085046291351318
Epoch: 34 Loss D.: 0.5054818391799927
Epoch: 34 Loss G.: 0.97736656665802
Epoch: 35 Loss D.: 0.501994252204895
Epoch: 35 Loss G.: 0.9651882648468018
Epoch: 36 Loss D.: 0.5797123312950134
Epoch: 36 Loss G.: 0.9834977984428406
Epoch: 37 Loss D.: 0.5798832178115845
Epoch: 37 Loss G.: 0.8607169985771179
Epoch: 38 Loss D.: 0.5732899904251099
Epoch: 38 Loss G.: 0.972059965133667
Epoch: 39 Loss D.: 0.5559769868850708
Epoch: 39 Loss G.: 0.9903337359428406
Epoch: 40 Loss D.: 0.6193569898605347
Epoch: 40 Loss G.: 0.8886935114860535
Epoch: 41 Loss D.: 0.5971341133117676
Epoch: 41 Loss G.: 1.0038079023361206
Epoch: 42 Loss D.: 0.5701870918273926
Epoch: 42 Loss G.: 0.8449660539627075
Epoch: 43 Loss D.: 0.6419569849967957
Epoch: 43 Loss G.: 1.0421513319015503
Epoch: 44 Loss D.: 0.5687682628631592
Epoch: 44 Loss G.: 1.0687079429626465
Epoch: 45 Loss D.: 0.5570292472839355
Epoch: 45 Loss G.: 1.00657320022583
Epoch: 46 Loss D.: 0.5906983613967896
Epoch: 46 Loss G.: 1.0181277990341187
Epoch: 47 Loss D.: 0.6377397775650024
```

```
Epoch: 47 Loss G.: 0.9799179434776306
Epoch: 48 Loss D.: 0.5957322716712952
Epoch: 48 Loss G.: 0.9374105334281921
Epoch: 49 Loss D.: 0.6317499279975891
Epoch: 49 Loss G.: 0.9757820963859558
```

```
print("loss_discriminator: ", loss_discriminator)
print("loss_generator: ", loss_generator)
```

```
loss_discriminator:  tensor(0.5798, device='cuda:0', grad_fn=<BinaryCrossEntropyBackward0>)
loss_generator:  tensor(0.9509, device='cuda:0', grad_fn=<BinaryCrossEntropyBackward0>)
```

```
with tick.marks(35):
    assert compare_numbers(new_representation(loss_discriminator), "3c3d", '0x1.3333333333333p-1'

with tick.marks(35):
    assert compare_numbers(new_representation(loss_generator), "3c3d", '0x1.8000000000000p+0')
```

✓ [35 marks]

✓ [35 marks]

Validación del Resultado

Para generar dígitos escritos a mano, es necesario tomar algunas muestras aleatorias del espacio latente y alimentarlas al generador.

Para trazar generated_samples, es necesario mover los datos de vuelta a la CPU en caso de que estén en la GPU. Para ello, simplemente se puede llamar a .cpu(). Como se hizo anteriormente, también es necesario llamar a .detach() antes de usar Matplotlib para trazar los datos.

La salida debería ser dígitos que se asemejen a los datos de entrenamiento. Después de cincuenta épocas de entrenamiento, hay varios dígitos generados que se asemejan a los reales. Se pueden mejorar los resultados considerando más épocas de entrenamiento. Al igual que en la parte anterior, al utilizar un tensor de muestras de espacio latente fijo y alimentarlo al generador al final de cada época durante el proceso de entrenamiento, se puede visualizar la evolución del entrenamiento.

Se puede observar que al comienzo del proceso de entrenamiento, las imágenes generadas son completamente aleatorias. A medida que avanza el entrenamiento, el generador aprende la distribución de los datos reales y, a algunas épocas, algunos dígitos generados ya se asemejan a los datos reales.

```
latent_space_samples = torch.randn(batch_size, 100).to(device=device)
generated_samples = generator(latent_space_samples)
```

```
generated_samples = generated_samples.cpu().detach()
for i in range(16):
    ax = plt.subplot(4, 4, i + 1)
    plt.imshow(generated_samples[i].reshape(28, 28), cmap="gray_r")
    plt.xticks([])
    plt.yticks([])
```

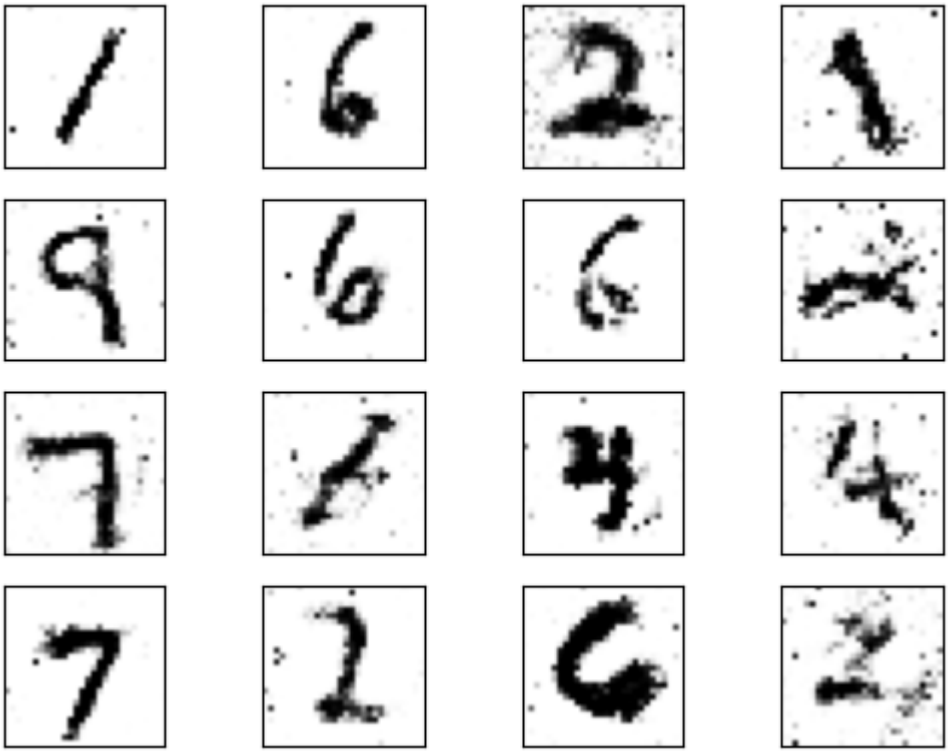

```
# Visualización del progreso de entrenamiento
# Para que esto se ve bien, por favor reinicien el kernel y corran todo el notebook

from PIL import Image
from IPython.display import display, Image as IPImage

images = [Image.open(path) for path in list_images]

# Save the images as an animated GIF
gif_path = "animation.gif"  # Specify the path for the GIF file
images[0].save(gif_path, save_all=True, append_images=images[1:], loop=0, duration=1000)
display(IPImage(filename=gif_path))
```

```
<IPython.core.display.Image object>
```

Las respuestas de estas preguntas representan el 30% de este notebook

PREGUNTAS: * ¿Qué diferencias hay entre los modelos usados en la primera parte y los usados en esta parte? - Una de las diferecias es que en la primera parte se usaron datos de una funcion seno, mientras que en esta parte se usaron imagenes de numeros escritos a mano. Otra diferencia es que en la primera parte se usaron modelos mas simples, mientras que en esta parte se usaron modelos mas complejos debido a las coversiones necesarias a tensores. * ¿Qué tan bien se han creado las imagenes esperadas? - Al observar la imagen generada de la ultima epoca, se puede ver que los numeros generados son faciles de identificar, excepto por uno. Sin embargo, el resto de los numeros generados presentan una similitud notoria a los numeros reales. * ¿Cómo mejoraría los modelos? - Debido a la complejidad de los datos generados por MNIST, se podria mejorar el modelo aumentando el numero de epocas, o aumentando el numero de capas de los modelos. * Observe el GIF creado, y describa la evolución que va viendo al pasar de las epocas - Al principio los numeros generados son completamente ruido aleatorio, pero a medida que pasan las epocas, los numeros generados se van pareciendo mas a los numeros reales. Al final de las epocas, se puede ver que los numeros generados son muy parecidos a los numeros reales.

```
print()
print("La fraccion de abajo muestra su rendimiento basado en las partes visibles de este laborato
tick.summarise_marks() #
```

```
La fraccion de abajo muestra su rendimiento basado en las partes visibles de este laboratorio
```

70 / 70 marks (100.0%)